T.C.
SİVAS CUMHURİYET ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Bilgisayarlı Tomografi Görüntülerinden İnme Tespiti İçin Bilgi Damıtma Tabanlı Derin Öğrenme Modelleri ile Otomatik Tespiti

Esra KOÇ
Melis KILIÇ

Haziran-2025
SİVAS

TEZ BİLDİRİMİ

Bu tezdeki bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve tez yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

Esra KOÇ

Melis KILIÇ

Tarih: 23.06.2025

ÖZET

Bilgisayarlı Tomografi Görüntülerinden İnme Tespiti İçin Bilgi Damıtma Tabanlı Derin Öğrenme Modelleri ile Otomatik Tespiti

Esra KOÇ
Melis KILIÇ

Doç. Dr. Kali GÜRKAHRAMAN

Bu çalışma, Bilgisayarlı Tomografi (BT) görüntülerinden inme varlığının erken ve doğru şekilde tespit edilmesini sağlamak amacıyla, derin öğrenme tabanlı yenilikçi bir teşhis sistemi geliştirmeyi hedeflemektedir. Çalışmanın özgün değeri; bilgi damıtma (knowledge distillation) ve toplu (ensemble) öğrenme yöntemlerinin bir arada kullanılarak, düşük parametre boyutuna sahip, hızlı çalışan ve yüksek doğruluk sağlayan bir yapay zekâ modeli sunulmasında yatmaktadır. Araştırma kapsamında yedi farklı transfer öğrenme tabanlı derin öğrenme modeli (ResNet18, ResNet50, DenseNet121, DenseNet201, EfficientNetB0, EfficientNetB3 ve InceptionV3) karşılaştırılmış ve en yüksek performansı gösteren InceptionV3 modeli, öğretmen model olarak belirlenmiştir. Ardından bilgi damıtma yöntemi kullanılarak daha sade ve hesaplama açısından verimli öğrenci modeller eğitilmiştir. Bu öğrenci modellerin çıktıları topluluk öğrenme yaklaşımı ile birleştirilmiş ve sınıflandırma başarımlarında anlamlı bir artış sağlanmıştır. Geliştirilen modellerin performansı doğruluk, kesinlik, duyarlılık ve F1 skoru gibi ölçütlerle ayrıntılı şekilde değerlendirilmiş; ayrıca dış doğrulama verileri ile yapılan testler sayesinde sistemin genellenebilirliği analiz edilmiştir. Projenin yaygın etkisi, inme gibi yaşamı tehdit eden bir sağlık sorununu erken evrede tespit ederek müdahale süreçlerini hızlandırmakta, sağlık sistemine zaman ve maliyet açısından önemli katkılar sunmaktadır. Elde edilen bulgular, yapay zekâ tabanlı klinik karar destek sistemlerinin geliştirilmesine yönelik hem akademik hem de uygulamalı alanda önemli bir referans niteliği taşımaktadır.

Anahtar Kelimeler: İnme, derin öğrenme, bilgi damıtma, toplu öğrenme.

İÇİNDEKİLER

ÖZET ..... **iv**

İÇİNDEKİLER ..... **v**

KISALTMALAR ..... **vi**

1. GİRİŞ **1**

2. KAYNAK ARAŞTIRMASI **2**

3. MATERYAL VE YÖNTEM **4**

3.1. Veri Seti 4
3.2. Kullanılan Modeller ve Mimari Yapı 5
3.3. Bilgi Damıtma 6
3.4. Topluluk (Ensemble) Model 6

4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA **8**

4.1. Transfer Öğrenme Modellerinin Performansı 8
4.2. Bilgi Damıtma Süreci ve Öğrenci Modeller 11
4.3. Dış Doğrulama Analizi 11

5. SONUÇLAR VE ÖNERİLER **12**

KAYNAKLAR **13**

KISALTMALAR

Kısaltmalar

(BT: Bilgisayarlı Tomografi)

(MRG: Manyetik Rezonans Görüntüleme)

(KD: Knowledge Distillation)

(DL: Deep Learning)

1. GİRİŞ

İnme, dünya genelinde milyonlarca ölüme ve kalıcı sağlık sorunlarına yol açan ciddi bir hastalıktır. Beyin dokusuna giden kan akışının ani kesilmesiyle meydana gelen bu durum, kısa sürede kalıcı fonksiyon kayıplarına yol açabilmektedir. Dünya Sağlık Örgütü verilerine göre, küresel ölümlerin yaklaşık %12'si inme kaynaklıdır. Bu bağlamda, erken teşhis ve müdahale hayati önem taşımaktadır [1].

İnme tanısında görüntüleme teknolojileri önemli rol oynamaktadır. Kontrastsız Bilgisayarlı Tomografi, hızlı ve yaygın erişilebilirliği sayesinde Manyetik Rezonans Görüntüleme yöntemine kıyasla daha sık tercih edilmektedir. Ancak görüntülerin yorumlanması zamana duyarlıdır ve uzman yorumu gerektirir. Bu nedenle, yapay zekâ tabanlı çözümler özellikle görüntü tabanlı inme tanısında giderek daha yaygın biçimde kullanılmaktadır [2].

Bu çalışmada, kontrastsız BT görüntüleri kullanılarak inme var/yok sınıflandırması yapılmış, farklı mimarilere sahip yedi transfer öğrenme tabanlı derin öğrenme modeli eğitilmiştir. Ardından, en yüksek başarıyı gösteren model öğretmen model olarak seçilerek bilgi damıtma yöntemi uygulanmış ve daha küçük öğrenci modeller geliştirilmiştir. Son olarak, bu öğrenci modellerin çıktıları topluluk (ensemble) yöntemi ile birleştirilerek sınıflandırma başarımı artırılmıştır. Bu yaklaşım, klinik kararlara destek sunabilecek etkili ve genellenebilir bir sistem tasarlanmasını hedeflemektedir.

2. KAYNAK ARAŞTIRMASI

İnme, beyin damarlarında tıkanıklık (iskemik) ya da kanama (hemorajik) sonucu ortaya çıkan ve erken müdahale edilmediğinde kalıcı hasarlara yol açabilen ciddi bir sağlık problemidir. Bu durum, dünya genelinde önde gelen ölüm nedenlerinden biri olup, özellikle ileri yaş gruplarında yaşam kalitesini önemli ölçüde düşürmektedir.

Literatürde yapılan çalışmalar, inme tanısının erken konulabilmesi için yapay zekâ tabanlı modellerin oldukça etkili olduğunu ortaya koymaktadır. Özellikle derin öğrenme teknikleriyle geliştirilen modeller, beyin görüntülerinin otomatik olarak sınıflandırılması ve segmentasyonu süreçlerinde yüksek doğruluk oranlarıyla dikkat çekmektedir.

Örneğin, Uçkun vd. [3] tarafından yapılan çalışmada, U-Net ve varyasyonlarının (VGG16, VGG19, Attention U-Net, ResU-Net) kullanıldığı bir segmentasyon modeli ile %96,95 kesişim-birleşim oranı elde edilmiştir. Bu çalışmada, Koç vd. [4] tarafından oluşturulan veri setinde yalnızca iskemik inme olarak etiketlenmiş görüntüler kullanılmıştır.

Kaya ve Önal [5], önce inme türlerini sınıflandırmış ve ardından U-Net tabanlı modelle segmentasyon yaparak %95,06 doğruluk ve %92,01 (hemorajik), %82,22 (iskemik) IoU değerleri elde etmiştir.

Yalçın ve Vural [6], verilerde denge sağlamak amacıyla veri artırma teknikleri uygulamış; ardından geliştirdikleri sınıflandırma ve segmentasyon modelinde %98,90 doğruluk (inme var/yok) ve %98,50 doğruluk (iskemik/hemorajik) başarı elde etmişlerdir. Benzer şekilde, Alhatemi ve Savaş [7], MRG görüntüleri ile gerçekleştirdikleri çalışmada EfficientNetB2 modelinden %98,80 doğruluk almıştır.

Karataş vd. [8], çalışmalarında Koç vd. [4] tarafından oluşturulan ve normal, iskemik ve hemorajik olarak etiketlenmiş BT görüntülerinden oluşan veri setini kullanmıştır. İki aşamalı sınıflandırma modelinde, önce ResNet50 ile inme var/yok %99,72 doğrulukla tespit edilmiştir, ardından inmenin türü (iskemik/hemorajik) Inception-v3 kullanılarak %99,51 doğrulukla hesaplanmıştır.

Son olarak, Ferdous ve Shahriyar [9], 2515 BT görüntüsü üzerinde InceptionV3 ve Xception modellerinin çıktılarından oluşan bir topluluk (ensemble) modeli olan

ENSNET ile %98,86 doğruluk, %97,71 kesinlik, %98,46 duyarlılık ve %98,08 F1 skoru elde etmişlerdir. Bu çalışma, farklı modellerin çıktılarının birleştirilmesinin performansı önemli ölçüde artırabileceğini göstermektedir.

Çizelge 1. İnme sınıflandırma/segmentasyon ile ilgili literatür derlemesi

Çalışma	Veri Seti	Model	Sınıflandırma	Segmentasyon
Uçkun vd. [3]	Koç vd. [4] BT görüntüleri	U-Net, VGG16, VGG19, Attention U-Net, ResU-Net	-	%96,95 IoU
Kaya ve Önal [5]	Koç vd. [4] BT görüntüleri	U-Net tabanlı model	%95,06 doğruluk	%92,01 (hemorajik) / %82,22 (iskemik) IoU
Yalçın ve Vural [6]	Koç vd. [4] BT görüntüleri	Sınıflandırma modeli	%98,9 doğruluk (inme var/ yok) %98,5 (iskemik-hemorajik) doğruluk	
Alhatemi ve Savaş [7]	Kaggle MRG verileri	DenseNet121, ResNet50, Xception, MobileNet, VGG16, EfficientNetB2	%98,8 doğruluk (EfficientNetB2)	-
Karataş vd. [8]	Koç vd. [4] BT görüntüsü	ResNet50, Inception-v3	%99,72 doğruluk (inme var/yok) %99,51 doğruluk (inme türü)	
Ferdous ve Shahriyar [9]	Kaggle 2515 BT görüntüsü	InceptionV3+Xception (toplu)	%98,86 doğruluk	-

Yapılan bu çalışmalar, yapay zekânın teşhis süresini önemli ölçüde kısalttığını ve inme sınıflandırmasında transfer öğrenme tabanlı DL modellerinin yüksek başarı sağladığını, topluluk yaklaşımlarının ise bu başarıyı daha da artırdığını göstermektedir. Bu doğrultuda, çalışmamızda farklı transfer öğrenme modelleri kullanılmış, modellerin çıktıları toplu öğrenme yöntemiyle birleştirilmiştir. Ayrıca, bilgi damıtma yöntemi ile birden fazla modelin bilgi birikimi daha sade bir öğrenci modele aktarılmış; böylece hem doğruluk hem de hesaplama verimliliği hedeflenmiştir [10]. Bu yaklaşım, literatürdeki yöntemlerle rekabet edebilecek düzeyde performans sergileyen, genellenebilir ve klinik uygulamalara entegre edilebilir bir yapay zekâ destekli inme tanı sistemi sunmaktadır.

3. MATERYAL VE YÖNTEM

Bu çalışmada, BT görüntülerine dayalı olarak transfer öğrenme tabanlı DL modellerinden ResNet18, Resnet50, DenseNet121, DenseNet201 Inceptionv3, EfficientNetb0 ve EfficientNetb3 kullanılacak ve en iyi performans gösteren model, öğretmen model olarak seçilecektir. Öğretmen model, KD yöntemiyle öğrenci modellere aktarılacak ve bu sayede daha hızlı ve düşük boyutlu modeller elde edilecektir. Ayrıca projede, KD tabanlı yöntemlerin sonuçları bir toplu öğrenme modelinde birleştirilerek inme var/yok sınıflandırılması için nihai sonuç üretilecektir.

3.1. Veri Seti

Veri seti, T.C. Sağlık Bakanlığı Açık Veri Portalı üzerinden sağlanmıştır. Veri setinde "İnme Yok", "İskemi" ve "Kanamalı" olmak üzere üç farklı üç sınıfa ait BT görüntülerini içermektedir (https://acikveri.saglik.gov.tr/Home/DataSetDetail/1). Bu çalışmada ikili sınıflandırma amacı güdüldüğünden "İskemi" ve "Kanamalı" görüntüler "İnme Var" kategorisinde birleştirilmiştir. Veriler, %80 eğitim ve %20 test şeklinde ayrılarak üçlü çapraz doğrulama (cross-validation) senaryosuna göre modellenmiştir.

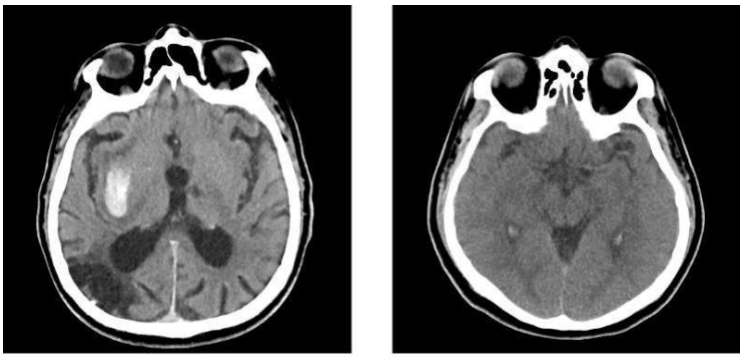

Şekil 1. Veri setindeki BT görüntüleri

Sınıf dengesizliğini azaltmak amacıyla veri artırma teknikleri uygulanmıştır. Bu kapsamda veriler %80 eğitim ve %20 test olacak şekilde, üç çapraz doğrulama (CV) senaryosu ile ayrılmıştır. -10° ile +10° arası döndürme, %10 oranında yakınlaştırma, ±10

piksel kaydırma ve yatay çevirme gibi yöntemlerle eğitim veri seti çeşitlendirilmiş. Bu işlemler sonucunda test veri seti 750x2 orijinal görüntüden oluşurken, eğitim veri seti 7500 görüntüye çıkarılmış ve toplamda 15000 eğitim, 1500 test görüntüsü elde edilmiştir. Görseller, tensör formatına dönüştürülmüş ve 256x256 piksel çözünürlüğe normalize edilmiştir. Sadece InceptionV3 modeli için 299x299 çözünürlük kullanılmıştır.

3.2. Kullanılan Modeller ve Mimari Yapı

Çalışmada 7 farklı transfer öğrenme tabanlı DL mimarisi test edilmiştir: ResNet18, ResNet50, DenseNet121, DenseNet201, EfficientNetB0, EfficientNetB3 ve InceptionV3. Bu modellerin her biri, önceden eğitilmiş ağırlıklarla ilklendirilmiş ve ardından 256 nörondan oluşan iki tam bağlantılı katmanla yeniden yapılandırılmıştır. Sınıflandırma işlemi, softmax aktivasyon fonksiyonu ile gerçekleştirilmiştir.

İlk aşamada tüm modeller bağımsız olarak eğitilmiş ve doğruluk, kesinlik, duyarlılık, F1 skoru gibi metriklerle değerlendirilmiştir. İkinci aşamada en iyi performans gösteren model (InceptionV3), öğretmen model olarak seçilmiştir. Bilgi damıtma sürecinde öğretmen modelin yumuşatılmış çıktıları (soft labels) öğrenci modellere aktarılmıştır. Bu işlem, sıcaklık (temperature) değeri 5.0 ve dengeleme katsayısı (α) 0.7 olacak şekilde optimize edilmiştir.

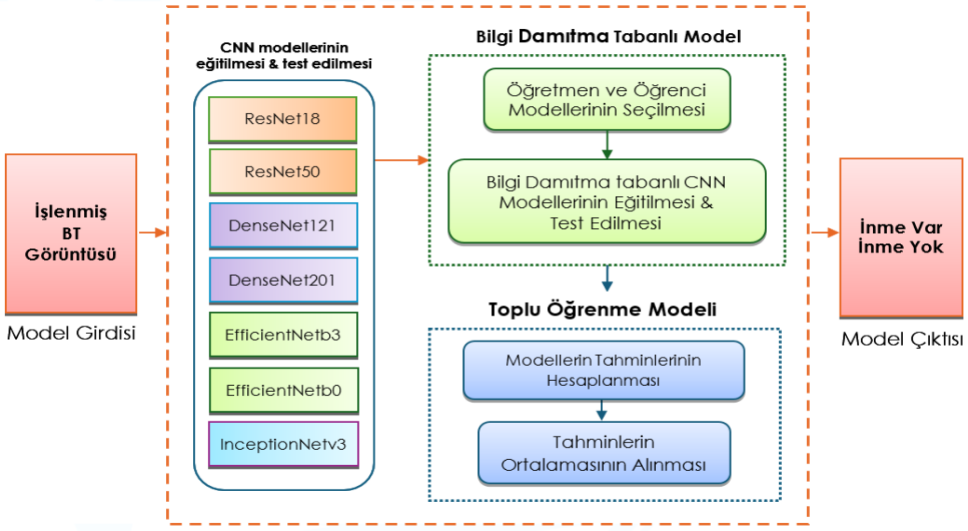

Şekil 2. İnme sınıflandırılması için önerilen DL sistemi

3.3. Bilgi Damıtma

Bilgi damıtma, derin öğrenme modellerinin daha verimli hâle getirilmesini sağlayan etkili bir yöntemdir. Bu yaklaşımda öncelikle yüksek doğruluk sağlayan büyük ve karmaşık bir model (öğretmen model) ya da bir model topluluğu (ensemble) eğitilir. Ardından, daha küçük boyutlu ve daha az hesaplama gücüne ihtiyaç duyan bir model (öğrenci model), öğretmen modelin rehberliğinde eğitilir. Bu rehberlik, öğretmen modelin çıktıları üzerine uygulanan softmax işlemi ile elde edilen yumuşatılmış olasılık dağılımları aracılığıyla sağlanır. Bu süreç sayesinde öğrenci model, yalnızca etiket bilgisinden değil, aynı zamanda öğretmenin sahip olduğu sınıf ayrımı bilgileri gibi daha ince ipuçlarından da faydalanarak öğrenir. Bu yöntemle eğitilen öğrenci modellerin, öğretmen modelin performansına yakın veya benzer sonuçlar elde edebildiği literatürde gösterilmiştir [11].

Bu konuda benzer yaklaşımlar daha önce farklı bakış açılarıyla da ele alınmıştır. Örneğin, Bucilua vd. [12], bilgi damıtmayı küçük bir etiketli veri kümesi üzerinde model eğitmek yerine, çeşitli taban sınıflayıcılardan oluşan bir topluluk modeliyle eğitmiştir. Büyük bir etiketlenmemiş veri kümesini etiketleyip, ardından bu geniş veri seti üzerinde tek bir model eğiterek çalışmıştır. Ba ve Caruana [13] ise, öğretmen modelin çıkışındaki değerleri taklit etmek amacıyla öğrenci modele L2 kaybı uygulanmasını önermiştir.

Luo vd. [14], öğretmen ve öğrenci modellerin üst katmanlarındaki özellik haritalarının L2 kaybı ile eşleştirilmesinin etkili sonuçlar verdiğini ortaya koymuştur. Yim vd. [15] ise, her bir katmandaki özellik haritalarından elde edilen matrisler üzerinden bilgi aktarımı gerçekleştirmiş ve öğretmen modelle aynı derinliğe sahip öğrenci modelin bu matrisler üzerinden L2 kaybı ile eğitilmesinin başarılı sonuçlar doğurduğunu göstermiştir.

3.4. Topluluk (Ensemble) Model

Üçüncü ve son aşamada, KD yöntemiyle eğitilen öğrenci modellerin çıktıları topluluk modeli içinde birleştirilmiştir. Bu birleşim sürecinde en yüksek doğruluk, kesinlik ve F1 skorunu EfficientNetB0 + EfficientNetB3 + DenseNet201 + ResNet18 +

ResNet50 + DenseNet121 kombinasyonu ile %98,3 olarak elde edilmiştir. Tüm modellerin eğitim süreci Python diliyle PyTorch kütüphanesi kullanılarak Google Colab Pro+ ortamında gerçekleştirilmiştir. Aşırı öğrenmeyi önlemek ve genel performansı artırmak amacıyla veri artırma tekniklerine ek olarak Adam optimizasyon algoritması ve çapraz entropi kayıp fonksiyonu kullanılmıştır. Eğitim sürecinde 32 batch size, 50 epoch, 0.0001 öğrenme oranı ve 0.9 momentum değeri kullanılmıştır.

4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

Bu çalışmada kullanılan derin öğrenme modelleri PyTorch kütüphanesi aracılığıyla Google Colab Pro+ ortamında geliştirilmiştir. Modellerin performansı doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1 skoru (F1-score) metrikleriyle değerlendirilmiştir. Eğitim süreci boyunca veri artırma teknikleri ve çapraz doğrulama stratejileri kullanılarak genellenebilirlik güçlendirilmiştir.

4.1. Transfer Öğrenme Modellerinin Performansı

Çizelge 2'ye göre, F1 skoru açısından yapılan değerlendirmede CV1 alt kümesinin tüm modeller için en yüksek başarımların elde edildiği alt küme olduğu görülmektedir. Modellerin genel F1 skorları %96,9 ila %98,1 arasında değişmekte olup, InceptionV3 modeli %97,6 ortalama F1 skoru ile en iyi genel performansı göstermiştir. Aynı zamanda, CV1 alt kümesinde %98,1 F1 skoru ile tüm modeller arasında en yüksek değere ulaşmıştır.

Bu nedenle InceptionV3 modeli, bilgi damıtma sürecinde öğretmen model olarak tercih edilmiştir. Çizelge 3'te, bu öğretmen modeli temel alınarak KD yöntemiyle eğitilen öğrenci modellere ait sınıflandırma başarımları yer almaktadır. Bu tabloda, ortalama F1 skoru bakımından %98,0 ile en iyi sonucu EfficientNetB0 modeli vermiştir. EfficientNetB0 modeli ayrıca ortalama doğruluk (%98,0) ve ortalama kesinlik (%99,5) açısından da öne çıkmaktadır.

Bu veriler, EfficientNetB0 modelinin hem KD sürecine yüksek düzeyde adapte olabildiğini hem de sınıflandırma görevlerinde oldukça başarılı sonuçlar üretebildiğini göstermektedir. Tüm KD tabanlı öğrenci modellerin ortalama performanslarının birbirine yakın olması ise InceptionV3 öğretmen modelinin bilgi aktarımındaki etkinliğini ortaya koymaktadır.

Çizelge 2. TF modellerinin inme sınıflandırma performans sonuçları

DL	Alt Küme	F1	P*	R	Acc	DL	Alt Küme	F1	P*	R	Acc
ResNet18	**CV1**	**0,976**	0,993	0,960	0,977	ResNet50	**CV1**	**0,974**	0,982	0,965	0,974
	CV2	0,970	0,992	0,949	0,971		CV2	0,969	0,993	0,945	0,969
	CV3	0,972	0,990	0,955	0,973		CV3	0,965	0,987	0,943	0,965
	Ort*	0,973	0,992	0,955	0,973		Ort	0,969	0,988	0,951	0,970

DenseNet121	**CV1**	**0,976**	0,992	0,960	0,976	DenseNet201	**CV1**	**0,977**	0,990	0,964	0,977
	CV2	0,974	0,981	0,967	0,974		CV2	0,971	0,988	0,955	0,971
	CV3	0,972	0,999	0,947	0,973		CV3	0,968	0,993	0,944	0,969
	Ort	0,974	0,990	0,958	0,974		Ort	0,972	0,990	0,954	0,972
EfficientNetb3	**CV1**	**0,980**	0,992	0,969	0,981	EfficientNetb0	**CV1**	**0,980**	0,987	0,973	0,980
	CV2	0,972	0,986	0,959	0,973		CV2	0,977	0,990	0,964	0,977
	CV3	0,973	0,999	0,949	0,974		CV3	0,969	0,994	0,945	0,970
	Ort	0,975	0,992	0,959	0,976		Ort	0,975	0,990	0,961	0,976
Inceptionv3	**CV1**	**0,981**	**0,991**	**0,971**	**0,981**						
	CV2	0,976	0,993	0,960	0,977						
	CV3	0,971	0,993	0,949	0,971						
	Ort	**0,976**	**0,992**	**0,960**	**0,976**						

*P: precision-kesinlik, R: recall-duyarlılık ve Acc: Accuracy-doğruluk, Ort: Ortalama

Çizelge 3. KD yöntemiyle eğitilen modellerin performans sonuçları

DL	Alt Küme	F1	P*	R	Acc	DL	Alt Küme	F1	P*	R	Acc
Resnet18	CV1	0,978	0,990	0,965	0,978	Resnet50	CV1	0,976	0,992	0,961	0,977
	CV2	0,976	0,995	0,957	0,976		CV2	0,975	0,993	0,957	0,975
	CV3	0,976	0,997	0,956	0,977		CV3	0,975	0,999	0,952	0,975
	Ort*	0,976	0,994	0,960	0,977		Ort	0,975	0,994	0,957	0,976
Densenet121	CV1	0,975	0,982	0,968	0,975	Densenet201	CV1	0,978	0,995	0,963	0,979
	CV2	0,977	0,992	0,963	0,977		CV2	0,976	0,997	0,956	0,977
	CV3	0,972	0,999	0,947	0,973		CV3	0,976	0,997	0,956	0,977
	Ort	0,975	0,991	0,959	0,975		Ort	0,977	0,996	0,958	0,977
EfficientNetb3	CV1	0,980	0,997	0,964	0,981	**EfficientNetb0**	CV1	0,982	0,996	0,969	0,983
	CV2	0,976	0,997	0,955	0,976		CV2	0,982	0,995	0,969	0,982
	CV3	0,976	0,996	0,957	0,977		CV3	0,975	0,996	0,955	0,975
	Ort	0,977	0,997	0,959	0,978		**Ort**	**0,980**	**0,995**	**0,964**	**0,980**

*P: precision-kesinlik, R: recall-duyarlılık ve Acc: Accuracy-doğruluk, Ort: Ortalama

Çizelge 4. KD yöntemiyle eğitilen modellerin performans sonuçları

KD tabanlı Toplu Öğrenme Modeli	**F1**	**P**	**R**	**Acc**
EfficientNetb0 + EfficientNetb3 + Densenet201 + Resnet18 + Resnet50 + Densenet121	**0,983**	0,983	0,983	0,983
EfficientNetb0 + EfficientNetb3 + Densenet201 + Resnet18 + Resnet50	0,982	0,982	0,982	0,982
EfficientNetb0 + EfficientNetb3 + Densenet201 + Resnet18	0,982	0,983	0,982	0,982

EfficientNetb0 + EfficientNetb3 + Densenet201	0,981	0,981	0,981	0,981
EfficientNetb0 + EfficientNetb3	0,982	0,982	0,982	0,982

*P: precision-kesinlik, R: recall-duyarlılık ve Acc: Accuracy-doğruluk,

Çizelge 4'te sunulan bulgular, KD tabanlı bireysel modellerin birleştirilmesiyle oluşturulan topluluk modelin, inme sınıflandırmasında belirgin bir performans artışı sağladığını göstermektedir. Altı farklı modelin bütünleştirilmesiyle elde edilen yapı, tüm değerlendirme ölçütlerinde %98,3 oranında üstün başarı sergilemiştir.

Bununla birlikte, yalnızca EfficientNetB0 ve EfficientNetB3 modellerinin birlikte kullanılmasıyla da %98,2 doğruluk ve F1 skoru elde edilmiştir. Bu durum, daha az sayıda modelle de benzer düzeyde yüksek başarı sağlanabileceğini ve topluluk mimarisinin farklı yapılandırmalara esnek şekilde uyum sağlayabileceğini göstermektedir.

Çizelge 4'te sunulan, önerilen KD tabanlı altı modelin birleşiminden oluşan topluluk modeli, "Veri Seti" bölümünde ayrıntıları verilen dış doğrulama (external validation) verisi üzerinde test edilmiştir. Bu test sonucunda model; %63,50 doğruluk (accuracy), %78,90 kesinlik (precision), %63,50 duyarlılık (recall) ve %57,89 F1 skoru elde etmiştir. Şekil 3'te, geliştirilen modellerin sınıflandırma performanslarını gösteren zıtlık (confusion) matrisleri yer almaktadır.

Şekil 3a'da, CV1 alt kümesi üzerinde KD yöntemiyle eğitilen EfficientNetB0 modelinin yüksek başarı gösterdiği ve özellikle "inme var/yok" sınıflandırmasında oldukça başarılı sonuçlar verdiği görülmektedir. Şekil 3b'de ise, aynı CV1 verileri üzerinde test edilen KD tabanlı topluluk modelinin performansı sunulmakta olup, bireysel modellere göre hata oranlarında bir miktar azalma gözlemlenmektedir.

Şekil 3c'de yer alan sonuçlar ise modelin dış doğrulama verisindeki performansını göstermektedir. Bu verilerde genel doğruluk oranı düşmekle birlikte, modelin "inme var" sınıfını tespit etmede hâlâ başarılı olduğu anlaşılmaktadır. Bu performans kaybında, doğrulama veri setinin farklı bir kaynaktan alınmış olması, görüntülerin RGB renk formatındaki farklılıklar, histogram yapılarındaki uyumsuzluklar ile kullanılan BT cihazlarının marka-model farkları ve çekim protokollerindeki değişikliklerin etkili olduğu değerlendirilmektedir. Tüm bu farklılıklara rağmen, geliştirilen modelin çeşitliliği

yüksek ve daha gerçekçi senaryolarda da belirli bir genelleme yeteneği sergilediği söylenebilir.

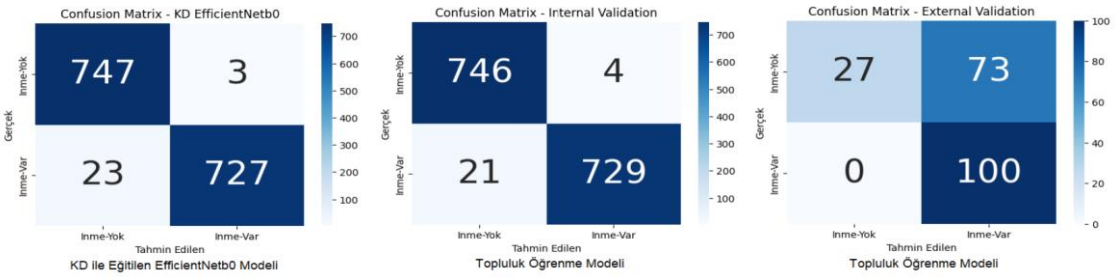

Şekil 3. Zıtlık matrisi, a) KD tabanlı Efficientb0, b) KD tabanlı toplu model, c) Toplu modelin External Validasyonu

4.2. Bilgi Damıtma Süreci ve Öğrenci Modeller

InceptionV3 modelinin çıktıları, bilgi damıtma yöntemiyle EfficientNet, DenseNet ve ResNet tabanlı öğrenci modellere aktarılmıştır. Bu süreçte sıcaklık (T=5.0) ve dengeleme katsayısı (α=0.7) değerleriyle eğitilen modellerin çoğu yüksek performans sergilemiştir. En başarılı öğrenci model olarak EfficientNetB0, ortalama %98,0 doğruluk, %99,5 kesinlik ve %98,0 F1 skoru ile öne çıkmıştır. Bu sonuçlar, öğretmen modelin öğrenci modellere etkili biçimde bilgi aktardığını göstermektedir.

Bilgi damıtma süreciyle elde edilen öğrenci modellerin çıktıları birleştirilerek topluluk öğrenme modeli oluşturulmuştur. Altı modelin birleşimiyle oluşturulan yapı, %98,3 doğruluk ve F1 skoru ile en yüksek sınıflandırma performansını göstermiştir. Bu yapı sayesinde daha güvenilir ve kararlı bir sınıflandırma başarısı elde edilmiştir. Yalnızca EfficientNetB0 ve EfficientNetB3 modelleri kullanıldığında %98,2 F1 skoru ile benzer başarı sağlanmıştır.

4.3. Dış Doğrulama Analizi

Geliştirilen topluluk modeli, dış bir veri seti üzerinde de test edilmiştir. Bu analiz sonucunda %63,50 doğruluk, %78,90 kesinlik, %63,50 duyarlılık ve %57,89 F1 skoru elde edilmiştir. Farklı kaynaklardan alınan görüntülerin histogram yapıları, renk formatları ve çekim protokollerindeki farklılıklar nedeniyle modelin performansı düşmüş olsa da “inme var” sınıfı için genel olarak başarılı bir tahmin yeteneği korunmuştur. Bu durum modelin belirli düzeyde genellenebilirlik kabiliyetine sahip olduğunu göstermektedir.

5. SONUÇLAR VE ÖNERİLER

Bu çalışmada, kontrastsız beyin BT görüntülerinden inme tespiti yapabilen bir yapay zekâ sınıflandırma sistemi geliştirilmiş ve transfer öğrenme yöntemleriyle yüksek doğruluk elde edilmiştir. Özellikle InceptionV3 modeli öğretmen model olarak öne çıkmış, bu modelden bilgi damıtma yoluyla EfficientNetB0, ResNet ve DenseNet gibi daha sade öğrenci modellere bilgi başarıyla aktarılmıştır. Bu öğrenci modellerin çıktılarının birleşimiyle oluşturulan topluluk (ensemble) modeli, %98,3 doğruluk, kesinlik, duyarlılık ve F1 skoru ile en yüksek sınıflandırma performansını göstermiştir. Dış veri seti üzerinde gözlenen kısmi performans düşüşlerine rağmen modelin genelleme yeteneği belirli düzeyde korunmuş, farklı veri kaynaklarına uyum sağlayabilecek esnek bir yapay zekâ çözümü elde edilmiştir.

Gelecek çalışmalarda modelin genellenebilirliğini artırmak amacıyla, farklı sağlık kurumlarından elde edilecek BT görüntüleriyle yeniden eğitme süreçleri gerçekleştirilmelidir. Bu sayede sistemin dış doğrulama performansı yükseltilerek, çeşitli klinik ortamlarda daha güvenilir sonuçlar elde edilmesi sağlanabilir. Ayrıca, geliştirilen yapay zekâ sistemi kullanıcı dostu bir arayüz ile birleştirilerek, doktorlara yönelik etkili bir karar destek sistemi hâline dönüştürülebilir. Model mimarisi açısından ise, transformer tabanlı modeller gibi yeni nesil rekabetçi yaklaşımların entegrasyonu, sınıflandırma başarısını daha da artırma potansiyeline sahiptir. Gerçek zamanlı uygulamalar için ise edge cihazlarda çalışabilecek şekilde optimize edilmiş, düşük donanım gereksinimi olan modellerin geliştirilmesi önem arz etmektedir. Son olarak, tıbbi yapay zekâ uygulamalarında etik, mahremiyet ve veri güvenliği gibi konular göz ardı edilmemeli, bu alanlar ilerleyen çalışmalarda kapsamlı şekilde ele alınmalıdır.

KAYNAKLAR

[1] World Health Organization. The top 10 causes of death. 2012 http:// www. who. int/ mediacentre/ factsheets/ fs310/ en/ index1. html2016.

[2] Pulli, B., Heit, J.J., & Wintermark, M. (2021). Computed tomography-based ımaging algorithms for patient selection in acute ischemic stroke. Neuroimaging Clinics of North America, 31(2), 235-250. https://doi.org/10.1016/j.nic.2020.12.002

[3] Uçkun, S., Ağarlı, M., & Kılıç, V. (2023). Deep Learning-Based Ischemic Stroke Segmentation on Brain Computed Tomography Images. Avrupa Bilim ve Teknoloji Dergisi, (50), 105-112.

[4] Koç, U., Sezer, E.A., Özkaya, Y.A., Yarbay, Y., Taydaş, O., Ayyıldız, V.A., Kızıloğlu, H.A., Kesimal, U., Çankaya, İ., Beşler, M.S., & Karakaş, E. (2022). Artificial intelligence in healthcare competition (Teknofest-2021): Stroke data set. The Eurasian Journal of Medicine, 54(3), 248.

[5] Kaya, B., & Önal, M. (2023). A CNN transfer learning-based approach for segmentation and classification of brain stroke from noncontrast CT images. International Journal of Imaging Systems and Technology.

[6] Yalçın, S., Vural, H. (2022). Brain stroke classification and segmentation using encoder–decoder based deep convolutional neural networks, Comput. Biol. Med. 149, 105941.

[7] Alhatemi, R.A.J., & Savaş, S. (2022). Transfer learning-based classification comparison of stroke. Computer Science, 192–201.

[8] Karataş, A.F., Doğan, V., & Kılıç, V. (2022). Artificial Intelligence-based Cerebrovascular Disease Detection on Brain Computed Tomography Images. Avrupa Bilim ve Teknoloji Dergisi, (41), 175-182.

[9] Ferdous, M.J., & Shahriyar, R. (2024). An ensemble convolutional neural network model for brain stroke prediction using brain computed tomography images. Healthcare Analytics, 6, 100368.

[10] Hinton, Geoffrey, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. arXiv preprint arXiv:1503.02531 (2015).

[11] A. Romero, N. Ballas, S. E. Kahou, A. Chassang, C. Gatta, and Y. Bengio, “Fitnets: Hints for thin deep nets,” in 3rd International Conference on Learning

Representations, ICLR, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings, 2015.

[12] C. Bucilua, R. Caruana, and A. Niculescu-Mizil, “Model compression,” in Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining, pp. 535–541, ACM, 2006.

[13] J. Ba and R. Caruana, “Do deep nets really need to be deep?,” in Advances in neural information processing systems, pp. 2654–2662, 2014.

[14] P. Luo, Z. Zhu, Z. Liu, X. Wang, and X. Tang, “Face model compression by distilling knowledge from neurons,” in Thirtieth AAAI Conference on Artificial Intelligence, 2016.

[15] J. Yim, D. Joo, J. Bae, and J. Kim, “A gift from knowledge distillation: Fast optimization, network minimization and transfer learning,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 4133–4141, 2017.